

1 Teoria della probabilità

1.1 Introduzione

Grazie al matematico sovietico Andrej Kolmogorov fu possibile, nel XX secolo, assiomatizzare i concetti fondamentali della teoria della probabilità.

Fra questi assiomi possiamo trovare le essenziali definizioni di:

Definizione 1. Si dice spazio campione l'insieme Ω (o semplicemente S) di tutti i possibili risultati, anche chiamati **eventi elementari**, di un esperimento aleatorio.

Definizione 2. Si dice spazio degli eventi $\mathcal{F} \subset \mathcal{P}(\Omega)$ la σ -algebra definita su Ω , i cui membri sono possibili **eventi** dell'esperimento aleatorio, ovvero combinazioni di **eventi elementari**.

Definizione 3. Si dice misura di probabilità P la misura definita su $\mathcal{F}$ che assegna ad ogni evento la sua **probabilità**.

Lo spazio misurabile $(\Omega, \mathcal{F}, P)$, insieme con l'assunzione che $P(\Omega) = 1$, è detto uno *spazio di probabilità*

1.2 Assiomi della teoria della probabilità

Assioma 1 (Non-negatività della probabilità). La probabilità di un evento deve sempre essere maggiore o uguale a zero

$$\forall E \in \mathcal{F}, P(E) \geq 0$$

Assioma 2 (Probabilità unitaria). La probabilità che il risultato di un esperimento aleatorio sia nell'insieme campione è sempre massima

$$P(\Omega) = 1$$

Assioma 3 (σ -additività). La probabilità associata ad un'unione numerabile di eventi mutualmente esclusivi ($\forall E_1, E_2 \in \{E_k\}_{k \in A}, E_1 \cap E_2 = \emptyset$) equivale alla somma delle probabilità degli eventi presi singolarmente

$$P\left(\bigcup_{k \in A} E_k\right) = \sum_{k \in A} P(E_k)$$

Gli assiomi 1 e 3 sono in realtà condizioni implicate dal fatto che lo spazio di probabilità è a sua volta uno spazio misurabile. Altre conseguenze degne di nota della proprietà di σ -additività sugli spazi di probabilità sono:

1. La misura di probabilità P è monotona, ovvero:

$$A \subseteq B \implies P(B) = P(A \cup (B \setminus A)) = P(A) + P(B \setminus A) \geq P(A)$$

2. La probabilità dell'evento nullo $\emptyset$ è nulla (l'evento è impossibile), $P(\emptyset) = 0$

3. Dato un evento E , la probabilità dell'evento complementare è data da $1 - P(E)$

$$1 = P(\Omega) = P(E \cup E^c) = P(E) + P(E^c) \implies 1 - P(E) = P(E^c)$$

4. Dati due eventi $A, B \in \mathcal{F}$, la probabilità della loro unione è data da $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

$$P(A \cup B) = P(A \setminus (A \cap B)) + P(B \setminus (A \cap B)) + P(A \cap B) = P(A) + P(B) - P(A \cap B)$$

2 Spazi di probabilità

2.1 Spazi di probabilità finiti

Uno spazio di probabilità finito è uno spazio in cui $|\Omega| = N < \infty$. La σ -algebra che consideriamo è solitamente l'insieme potenza di Ω , mentre siamo in grado di definire la misura di probabilità sugli eventi elementari, ovvero

$$\forall S_i \in \Omega, P(\{S_i\}) = p_i$$

In tal modo, per qualsiasi evento $E \in \mathcal{P}(\Omega)$, si ha che

$$P(E) = P\left(\bigcup_{S_k \in E} \{S_k\}\right) = \sum_{S_k \in E} P(\{S_k\})$$

2.2 Spazi di probabilità uniformi

Uno spazio di probabilità è detto uniforme qualora $\forall S_1, S_2 \in \Omega, P(\{S_1\}) = P(\{S_2\})$, ovvero quando la probabilità di tutti gli eventi elementari è la stessa. Questi possono essere finiti, quindi $\sum_{S_k \in \Omega} p_k = |\Omega| \cdot 1 \implies p_k = \frac{1}{|\Omega|}$, oppure infiniti, scegliendo la distribuzione di probabilità appropriata.

Uno spazio di probabilità uniforme non può avere insieme campione infinitamente numerabile, in quanto $p_k > 0 \implies p_k \cdot N > 1$ per qualche N sufficientemente grande, ma $|\Omega| = |\mathbb{N}| > N$.

3 Calcolo combinatorio

Definizione 4 (Disposizione). *Dato un insieme Ω , si dice disposizione n -esima il seguente insieme*

$$D_n(\Omega) = \{(\omega_1, \omega_2, \dots, \omega_n) : \omega_1, \dots, \omega_n \in \Omega\}$$

La cardinalità di $D_n(\Omega)$ è data da $|\Omega|^n$

Definizione 5 (Disposizione non ordinata). *Dato un insieme Ω , si dice disposizione n -esima non ordinata il seguente insieme*

$$D_n^*(\Omega) = D_n(\Omega) / (a \sim b \iff \text{Set}(a) = \text{Set}(b))$$

dove

$$t = (a_i)_{i \in I}, \quad f_t : i \mapsto a_i, \quad \text{Set}(t) = \text{Im}(f_t),$$

La cardinalità di $D_n^(\Omega)$ è data da $\sum_{i=1}^n \frac{|\Omega|!}{(|\Omega| - i)! i!} = \sum_{i=1}^n \binom{|\Omega|}{i}$*

Definizione 6 (Disposizione semplice). *Dato un insieme Ω , si dice disposizione n -esima semplice il seguente insieme*

$$D_n^s(\Omega) = \{(\omega_1, \omega_2, \dots, \omega_n) : \omega_1, \dots, \omega_n \in \Omega, \forall i, j \quad i \neq j \implies \omega_i \neq \omega_j\}$$

La cardinalità di $D_n^s(\Omega)$ è data da $\frac{|\Omega|!}{(|\Omega| - n)!}$

Definizione 7 (Disposizione semplice non ordinata). *Dato un insieme Ω , si dice disposizione semplice non ordinata n -esima il seguente insieme*

$$D_n^{s,*}(\Omega) = D_n^s(\Omega) / (a \sim b \iff \text{Set}(a) = \text{Set}(b))$$

La cardinalità di $D_n^{s,}(\Omega)$ è data da $\frac{|\Omega|!}{(|\Omega| - n)! n!} = \binom{|\Omega|}{n}$*

Definizione 8 (Permutazione). *Dato una tupla $t : I \rightarrow \Omega$, si dice permutazione di t la composizione di t con una biezione $\sigma : I \rightarrow I$ appartenente al gruppo simmetrico di I . In simboli*

$$P(t) = \{t \circ \sigma : \sigma \in \text{Sym}(I)\}$$

La cardinalità di $P(t)$ è data da $\frac{|I|!}{\prod_{e \in t(I)} |t^{-1}(e)|!}$

4 Probabilità condizionata

Dato uno spazio di probabilità $(\Omega, \mathcal{F}, P)$, si dice probabilità di un evento A condizionato ad un evento B la probabilità che avvenga A assunto B nuovo insieme campione. In altre parole, la probabilità condizionata $A|B$ è la probabilità che, considerando solo risultati in B , il risultato finale sia anche in A .

Operativamente, la probabilità condizionata $A|B$ è definita a partire dallo spazio di probabilità ereditato da B . Infatti, sia B il nuovo spazio campione; possiamo allora dimostrare che $\mathcal{F}_B = \{C \cap B : C \in \mathcal{F}\}$ sia a sua volta una valida σ -algebra:

1. Sia $\{S_i\}_{i \in I}$ una collezione numerabile di elementi di $\mathcal{F}_B$, allora

$$\bigcup_{i \in I} S_i = \bigcup_{i \in I} K_i \cap B = \left(\bigcup_{i \in I} K_i \right) \cap B$$

Dato che $\{K_i\}_{i \in I}$ è una collezione appartenente a $\mathcal{F}$, si ha che $\bigcup_{i \in I} K_i \in \mathcal{F}$, quindi $\bigcup_{i \in I} S_i \in \mathcal{F}_B$

2. Sia $\{S_i\}_{i \in I}$ una collezione numerabile di elementi di $\mathcal{F}_B$, allora

$$\bigcap_{i \in I} S_i = \bigcap_{i \in I} K_i \cap B = \left(\bigcap_{i \in I} K_i \right) \cap B$$

Dato che $\{K_i\}_{i \in I}$ è una collezione appartenente a $\mathcal{F}$, si ha che $\bigcap_{i \in I} K_i \in \mathcal{F}$, quindi $\bigcap_{i \in I} S_i \in \mathcal{F}_B$

3. Sia $A \in \mathcal{F}_B$, allora esiste $K \in \mathcal{F}$ tale per cui $A = K \cap B$. Dato che $K^c \in \mathcal{F}$, allora $K^c \cap B \in \mathcal{F}_B$. Per chiusura sotto contabile unione, si ha che $(K \cap B) \cup (K^c \cap B) \in \mathcal{F}_B$, da cui si evince

$$(K \cap B) \cup (K^c \cap B) = (K \cup K^c) \cap B = \Omega \cap B = B$$

Abbiamo quindi dimostrato che $A \cup (K^c \cap B) = B$. Tenendo conto che A e $K^c \cap B$ sono disgiunti, possiamo affermare di conseguenza che $K^c \cap B = A^c$ (in B), e quindi $\mathcal{F}_B$ è chiuso per complemento.

La misura di probabilità ereditata è la misura originale ristretta a $\mathcal{F}_B$ "normalizzata" secondo $P(B)$, ovvero

$$P_B(S) = \frac{P(S)}{P(B)}, \text{ dove } S = A \cap B \text{ per qualche } A \text{ in } \mathcal{F}$$

Di conseguenza, la terna $(B, \mathcal{F}_B, P_B)$ è un nuovo spazio di probabilità, e l'espressione $P(A|B)$ significa $P_B(A \cap B) = \frac{P(A \cap B)}{P(B)}$

4.1 Formula delle probabilità composte

Sia $(\Omega, \mathcal{F}, P)$ uno spazio di probabilità e sia $A_1, \dots, A_n$ una collezione di eventi tal per cui $P(\bigcap_{i=1}^n A_i) > 0$, allora

$$P\left(\bigcap_{i=1}^n A_i\right) = P(A_1) \cdot P(A_2|A_1) \cdot P(A_3|A_1 \cap A_2) \cdot \dots \cdot P(A_n|A_1 \cap A_2 \cap \dots \cap A_{n-1})$$

4.2 Formula delle probabilità totali

Sia $(\Omega, \mathcal{F}, P)$ uno spazio di probabilità e sia $\{A_i\}_{i \in I}$ una collezione di eventi tale per cui

$$i \neq j \implies A_i \cap A_j = \emptyset$$

$$\forall i \in I, P(A_i) \neq 0$$

$$\bigcup_{i \in I} A_i = \Omega$$

ovvero una partizione disgiunta dell'insieme campione Ω , allora, dato un generico evento $B \in \mathcal{F}$

$$P(B) = \sum_{i \in I} P(B \cap A_i) = \sum_{i \in I} P(A_i)P(B|A_i)$$

4.3 Formula di Bayes

Sia $(\Omega, \mathcal{F}, P)$ uno spazio di probabilità e siano $A, B \in \mathcal{F}$ due eventi. Allora

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(B|A)P(A)}{P(B)}$$

Sia $\{A_i\}_{i \in I} \subset \mathcal{F}$ una partizione disgiunta di Ω e sia $B \in \mathcal{F}$ un generico evento, allora

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{P(B)} = \frac{P(B|A_i)P(A_i)}{\sum_{j \in I} P(B|A_j)P(A_j)}$$

5 Indipendenza degli eventi

Sia $(\Omega, \mathcal{F}, P)$ uno spazio di probabilità e siano $A, B \in \mathcal{F}$ due eventi. A e B si dicono (statisticamente, stocasticamente) indipendenti (oppure, in simboli $A \perp B$) qualora si verifichi una delle seguenti condizioni:

1. $P(A|B) = P(A)$, se $P(B) > 0$.
2. $P(B|A) = P(B)$, se $P(A) > 0$
3. $P(A \cap B) = P(A|B)P(B) = P(B|A)P(A) = P(A)P(B)$

Intuitivamente, A e B sono indipendenti qualora la probabilità che accada A è la stessa sia in Ω che in B e viceversa.

Inoltre, è possibile fare una serie di osservazioni circa due eventi indipendenti, ovvero

1. $A \perp B \implies A \perp B^c$. Si osservi infatti come

$$P(A) = P(A \cap B) + P(A \cap B^c) = P(A)P(B) + P(A \cap B^c) \implies P(A)(1 - P(B)) = P(A \cap B^c)$$

2. $A \perp B \implies A^c \perp B$. Si osservi come

$$P(B) = P(A \cap B) + P(A^c \cap B) = P(A)P(B) + P(A^c \cap B) \implies P(B)(1 - P(A)) = P(A^c \cap B)$$

3. $A \perp B \implies A^c \perp B^c$. Si osservi come

$$P(A^c) = P(A^c \cap B) + P(A^c \cap B^c) \implies P(A^c)(1 - P(B)) = P(A^c \cap B^c)$$

4. E' possibile generalizzare il concetto di indipendenza a più eventi, ovvero, data una collezione di eventi $\{A_i\}_{i \in I}$, si ha che

$$P\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} P(A_i)$$
$$\forall i, j \in I, i \neq j \implies P(A_i \cap A_j) = P(A_i)P(A_j)$$

5.1 Indipendenza condizionata

Sia $(\Omega, \mathcal{F}, P)$ uno spazio di probabilità, e siano $A, B, C \in \mathcal{F}$ tre eventi tali per cui $P(C) > 0$. A e B si dicono indipendenti condizionatamente al verificarsi di C se

$$P(A \cap B|C) = P(A|C)P(B|C)$$

6 Variabili casuali

Definizione 9 (Variabile casuale). *Sia $(\Omega, \mathcal{F}, P)$ uno spazio di probabilità. Si definisce variabile casuale una qualsiasi funzione misurabile del tipo*

$$X : (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{G})$$

Una variabile casuale *trasporta* la misura di probabilità dello spazio di probabilità d'origine allo spazio misurabile determinato da $(E, \mathcal{G})$. In altre parole, grazie a X , si definisce la seguente misura su $(E, \mathcal{G})$

$$P_X(A \in \mathcal{G}) = P(X^{-1}(A))$$

Spesso, $E = \mathbb{R}$ e $\mathcal{G} = \mathcal{B}(\mathbb{R})$, ovvero le nostre variabili casuali avranno come codominio $\mathbb{R}$ e come σ -algebra quella di Borel.

Teorema 1 (Teorema del generatore). *Sia $(\Omega, \mathcal{F}, P)$ uno spazio di probabilità, e sia $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ una funzione. Se, per ogni $a \in \mathbb{R}$, si ha che*

$$X^{-1}((-\infty, a]) \in \mathcal{F}$$

Allora X è misurabile ed è una variabile casuale.

Dimostrazione. Si selezioni un generico $B \in \mathcal{B}(\mathbb{R})$. Questi è il prodotto di un'espressione *algebraica* dei membri del seguente generatore

$$G = \{(-\infty, a] : a \in \mathbb{R}\}$$

Dato che è possibile dimostrare che l'operatore di pullback commuta con le operazioni algebriche che determinano le σ -algebre, $X^{-1}(B)$ è a sua volta un'espressione algebrica di pullback di elementi del generatore. Dato che quest'ultimi si trovano in $\mathcal{F}$, allora anche il risultato dell'espressione si trova in $\mathcal{F}$. $\square$

Definizione 10 (Funzione di distribuzione cumulativa). *Sia $(\Omega, \mathcal{F}, P)$ uno spazio di probabilità, e sia $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ una variabile casuale. Si dice funzione di distribuzione cumulativa la seguente funzione*

$$F_X : \mathbb{R} \rightarrow [0, 1]$$

$$F_X(x) = P(X \leq x) = P_X((-\infty, x])$$

Alcune delle proprietà della funzione di distribuzione cumulativa sono:

- Limite verso $-\infty$

$$\lim_{x \rightarrow -\infty} F_X(x) = 0$$

- Limite verso $+\infty$

$$\lim_{x \rightarrow \infty} F_X(x) = 1$$

- Non-decrescenza

$$x_1 > x_2 \implies (-\infty, x_2] \subseteq (-\infty, x_1] \implies F_X(x_1) \geq F_X(x_2)$$

- Continuità da destra

$$\lim_{h \rightarrow 0^+} F_X(x+h) = F_X(x)$$

Definizione 11 (Variabili casuali indipendenti). *Siano $X_1, X_2 : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ delle variabili casuali. Queste si dicono indipendenti se $\forall I_1, I_2 \subseteq \mathbb{R}$ intervalli vale la seguente relazione*

$$P(X_1^{-1}(I_1) \mid X_2^{-1}(I_2)) = P(X_1^{-1}(I_1))$$

Lemma 1. *Sia $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ una variabile casuale e sia $g(x) : \mathbb{R} \rightarrow \mathbb{R}$ una funzione misurabile e iniettiva. Allora, dato un $B \in \mathcal{B}(\mathbb{R})$*

$$P(X \in B) = P(g(X) \in g(B))$$

Dimostrazione. Ricordando la definizione dell'espressione $P(X \in B)$, si ha che

$$P(X \in B) = P(\{\omega \in \Omega : X(\omega) \in B\}) = P(X^{-1}(B))$$

Per la proprietà iniettiva di g , si evince

$$g^{-1}(g(B)) = B$$

Si consideri allora l'espressione $(g \circ X)^{-1}$; è triviale infatti l'eguaglianza $(g \circ X)^{-1} = X^{-1} \circ g^{-1}$. Quindi (sia $g(B)$ scritto come gB per evitare troppe parentesi)

$$P(g(X) \in gB) = P((g \circ X)^{-1}(gB)) = P((X^{-1} \circ g^{-1})(gB)) = P(X^{-1}(B)) = P(X \in B)$$

□

6.1 Caratterizzazione delle variabili casuali

E' possibile caratterizzare le variabili casuali a seconda di come le misure di probabilità indotte dalle stesse sono formulate.

1. Se, data una variabile casuale X , la sua immagine $X(\Omega)$ è contabile, allora

$$\forall x_1, x_2 \in \Omega, X^{-1}(x_1) \cap X^{-1}(x_2) = \emptyset$$

di conseguenza, la seguente collezione di sottoinsiemi di Ω

$$\{X^{-1}(x) : x \in X(\Omega)\}$$

è una partizione disgiunta dello spazio campione, quindi

$$1 = P(\Omega) = \sum_{x \in X(\Omega)} P(X^{-1}(x)) = \sum_{x \in X(\Omega)} P(X = x)$$

X è allora detta una variabile casuale *discreta*.

2. Se, data una variabile casuale X , la sua *funzione di distribuzione cumulativa* $F_X(x)$ è continua, allora X è una variabile casuale (assolutamente) continua.

6.1.1 Variabili casuali discrete

Sia $(\Omega, \mathcal{F}, P)$ uno spazio di probabilità, e sia $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ una variabile casuale discreta. Dalla definizione fornita sopra, abbiamo che:

$$\forall B \in \mathcal{B}(\mathbb{R}), P_X(B) = P(X \in B) = \sum_{x \in X(\Omega) \cap B} P(X = x)$$

Teorema 2. Siano $X, Y : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ due variabili casuali discrete. Allora X e Y sono indipendenti se e solo se $P_{(X,Y)}(x) = P_X(x)P_Y(x)$

6.1.2 Variabili casuali continue

Sia $(\Omega, \mathcal{F}, P)$ uno spazio di probabilità, e sia $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ una variabile casuale continua, allora

$$\forall B \in \mathcal{B}(\mathbb{R}), P(X \in B) = \int_B f_X(x) dx = \int_B dP_X \text{ (nel senso di integrale di Lebesgue)}$$

dove f_X è detta (funzione di) densità di probabilità. Le proprietà della densità di probabilità di X sono:

1. La densità deve essere distribuita lungo tutto l'asse reale, ovvero

$$P(X \in \mathbb{R}) = \int_{-\infty}^{+\infty} f_X(x) dx = 1$$

2. La densità deve essere non-negativa, ovvero

$$\forall x \in \mathbb{R}, f_X(x) \geq 0$$

Un'importante osservazione sulle variabili casuali continue è la seguente: data una variabile casuale continua, è possibile determinare la funzione di distribuzione cumulativa a partire dalla densità introdotta dalla variabile. In altre parole

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(u) du \implies P(X \in (a, b)) = F_X(b) - F_X(a)$$

La garanzia di continuità della FDC ci è data dal fatto che questa è una funzione integrale, ovvero la primitiva di f_X . Di conseguenza, vale la seguente considerazione

$$f_X = \frac{d}{dx} F_X$$

Teorema 3. Siano $X, Y : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ due variabili casuali continue. Allora X e Y sono indipendenti se e solo se $f_{(X,Y)}(x) = f_X(x)f_Y(x)$

6.2 Media, varianza e valore atteso di variabili casuali

Definizione 12 (Definizione di valore atteso). Sia X una variabile casuale. Se X è discreta, allora il valore atteso (anche chiamato valor medio) di X , denotato con $\mathbb{E}[X]$ oppure con μ_X , è dato da

$$\mu_X = \mathbb{E}[X] = \sum_{x \in X(\Omega)} x \cdot P(X = x)$$

Qualora invece X fosse continua, si ha che

$$\mu_X = \mathbb{E}[X] = \int_{\mathbb{R}} x f_X(x) dx$$

Teorema 4 (Teorema dello statistico inconsapevole). Sia X una variabile casuale, e sia $g : \mathbb{R} \rightarrow \mathbb{R}$ una funzione regolare. Allora, $g \circ X : \Omega \rightarrow \mathbb{R}$ è a sua volta una variabile casuale. Il valore atteso su $g \circ X$ vale allora

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) f_X(x) dx$$

Grazie al Teorema dello statistico inconsapevole, alcune delle proprietà del valore atteso sono

1. Linearità secondo composizione:

$$\mathbb{E}[\alpha g(X) + \beta h(X)] = \alpha \mathbb{E}[g(X)] + \beta \mathbb{E}[h(X)]$$

2. Monotonia secondo funzione:

$$\forall x \in \mathbb{R}, g(x) \leq h(x) \implies \mathbb{E}[g(X)] \leq \mathbb{E}[h(X)]$$

Definizione 13 (Definizione di varianza). Sia X una variabile casuale e sia $\mathbb{E}[X] = \mu_X$ il suo valore atteso (da non confondere con la misura indotta da X). Allora, la varianza di X è data da

$$\text{var}(X) = \mathbb{E}[(x - \mu_X)^2] = \mathbb{E}[x^2 + \mu_X^2 - 2x\mu_X] = \mathbb{E}[x^2] + \mu_X^2 - 2\mu_X^2 = \mathbb{E}[x^2] - \mathbb{E}[X]^2$$

Alcune delle proprietà della varianza sono

- Non negatività:

$$\text{var}(X) = \mathbb{E}[x^2] - \mathbb{E}[X]^2$$

ma, ricordando che se $\text{var}(X) = \mathbb{E}[(x - \mu_X)^2]$, si arriva a

$$(x - \mu_X)^2 \geq 0 \implies \int_{\mathbb{R}} (x - \mu_X) f_X(x) dx \geq 0 \implies \text{var}(X) \geq 0$$

- $\text{var}(aX + b) = a^2 \text{var}(X)$

Definizione 14 (Definizione di deviazione standard). *Sia X una variabile casuale e sia $\text{var}(X)$ la sua varianza. La deviazione standard di X è data da*

$$\sigma(X) = \sqrt{\text{var}(X)}$$

Definizione 15 (Definizione di standardizzazione di variabile casuale). *Sia X una variabile casuale. Si dice variabile casuale standard di X la seguente variabile casuale*

$$Y = \frac{X - \mu_X}{\sigma(X)}$$

Infatti, la varianza e il valore atteso di una standardizzazione di una variabile casuale sono, rispettivamente

$$\text{var}(Y) = 1, \quad \mathbb{E}[Y] = 0$$

In quanto:

$$\mathbb{E}[Y] = \mathbb{E}\left[\frac{x - \mu_X}{\sigma(X)}\right] = \frac{1}{\sigma(X)} \mathbb{E}[x - \mu_X] = \frac{1}{\sigma(X)} (\mathbb{E}[X] - \mu_X) = 0$$

di conseguenza

$$\text{var}(Y) = \mathbb{E}\left[\frac{(x - \mu_X)^2}{\sigma(X)^2}\right] - \mathbb{E}[Y]^2 = \frac{\mathbb{E}[(x - \mu_X)^2]}{\text{var}(X)} - 0 = \frac{\text{var}(X)}{\text{var}(X)} = 1$$

6.3 Covarianza fra due variabili casuali

Definizione 16 (Definizione di covarianza). *Siano X, Y due variabili casuali. Si indica con il termine covarianza $\text{cov}(X, Y)$ la seguente quantità*

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)]$$

Qualora $\text{cov}(X, Y) > 0$, X e Y sono dette positivamente correlate e viceversa. Se $\text{cov}(X, Y) = 0$, allora X e Y sono dette scorrelate o non correlate.

Un'altro modo per esprimere analiticamente la covarianza è

$$\mathbb{E}[(X - \mu_X)(Y - \mu_Y)] = \mathbb{E}[XY - \mu_Y X - \mu_X Y + \mu_X \mu_Y] = \mathbb{E}[XY] - \mu_Y \mu_X - \mu_X \mu_Y + \mu_X \mu_Y = \mathbb{E}[XY] - \mu_Y \mu_X$$

Alcune delle proprietà principali della covarianza sono:

1. $X \perp Y \implies \text{cov}(X, Y) = 0$
2. $\text{cov}(X, X) = \text{var}(X)$
3. $\text{cov}(X, Y) = \text{cov}(Y, X)$
4. $\text{cov}(X, c) = 0$
5. $\text{cov}(\alpha X + \beta Y, \lambda Z + \mu K) = \alpha \lambda \text{cov}(X, Z) + \alpha \mu \text{cov}(X, K) + \beta \lambda \text{cov}(Y, Z) + \beta \mu \text{cov}(Y, K)$

Dalle proprietà (2) e (5) si deduce

$$\text{var}(aX + bY + c) = \text{cov}(aX + bY + c, aX + bY + c) = a^2 \text{var}(X) + b^2 \text{var}(Y) + 2ab \text{cov}(X, Y)$$

risulta allora che

$$X \perp Y \implies \text{var}(X + Y) = \text{var}(X - Y) = \text{var}(X) + \text{var}(Y)$$

Definizione 17 (Definizione di correlazione). *Siano X, Y due variabili casuali. Si indica con il termine coefficiente di correlazione lineare $\rho(X, Y)$ la seguente espressione*

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)\text{var}(Y)}}$$

Alcune delle proprietà della correlazione sono:

$$1. \forall a, b \in \mathbb{R}, \rho(aX, bY) = \rho(X, Y)$$

Infatti, riprendendo la definizione analitica di ρ , si ha che

$$\rho(aX, bY) = \frac{\text{cov}(aX, bY)}{\sqrt{\text{var}(aX)\text{var}(bY)}} = \frac{ab \text{cov}(X, Y)}{ab\sqrt{\text{var}(X)\text{var}(Y)}} = \rho(X, Y)$$

$$2. -1 \leq \rho(X, Y) \leq 1$$

$$3. \rho(X, Y) = \pm 1 \iff Y = aX + b$$

($\implies$) Siano U, V , rispettivamente

$$U = \frac{X - \mu_X}{\sigma_X}, \quad V = \frac{Y - \mu_Y}{\sigma_Y}$$

si ha che $\rho(U, V)$ vale

$$\rho(U, V) = \frac{\frac{1}{\sigma_X \sigma_Y} \text{cov}(X, Y)}{\frac{1}{\sigma_X \sigma_Y} \sqrt{\text{var}(X)\text{var}(Y)}} = \rho(X, Y) = \pm 1$$

di conseguenza

$$\rho(U, V) = \pm 1 \implies \text{cov}(U, V) = \pm 1 \implies \text{var}(U \mp V) = \text{var}(U) + \text{var}(V) \mp 2\text{cov}(U, V) = 0$$

ciò implica che

$$U \mp V = c \implies \mathbb{E}[U \mp V] = \mathbb{E}[c] \implies 0 = \mathbb{E}[c] \implies c = 0 \implies U = \pm V$$

allora

$$U = \pm V \implies \frac{X - \mu_X}{\sigma_X} = k \frac{Y - \mu_Y}{\sigma_Y} \implies Y = \frac{\sigma_Y}{\sigma_X k} X - \frac{\sigma_Y}{\sigma_X k} \mu_X + \mu_Y \quad \text{con } k = \rho(X, Y) = \pm 1$$

($\Leftarrow$) Sia $Y = aX + b$, allora

$$\rho(X, aX + b) = \frac{a \text{cov}(X, X)}{|a| \sqrt{\text{var}(X)\text{var}(X)}} = \text{sign}(a)$$

6.4 Modelli di variabili casuali

6.4.1 Variabili casuali normali

Un comune modello di variabile casuale è, per esempio, la *gaussiana* o *normale* avente media μ e deviazione standard σ :

$$X \sim \mathcal{N}(\mu, \sigma), \quad f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Dove i parametri μ e σ controllano diversi elementi della “campana”, tra cui

- μ rappresenta la posizione sull'asse x dell'asse di simmetria della gaussiana e del massimo della stessa.
- A σ è legata la “larghezza” della campana, ovvero, se $\sigma_1 < \sigma_2$, allora $X_1 \sim \mathcal{N}(\mu, \sigma_1)$ è più stretta di $X_2 \sim \mathcal{N}(\mu, \sigma_2)$.

Dimostriamo allora che valor medio e deviazione standard di una variabile casuale normale $X \sim \mathcal{N}(\mu, \sigma)$ siano, rispettivamente, μ e σ :

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = \int_{-\infty}^{\infty} (x-\mu) \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx + \mu \int_{-\infty}^{\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

Operando la seguente sostituzione

$$u = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \implies du = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \cdot -\frac{(x-\mu)}{\sigma^2} dx$$

Arriviamo a

$$\mathbb{E}[X] = \left[-\frac{\sigma}{\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \right]_{-\infty}^{\infty} + \mu \cdot 1 = 0 + \mu = \mu$$

Per quanto riguarda la varianza, si ha che

$$\text{var}(X) = \mathbb{E}[(x-\mu)^2] = \int_{-\infty}^{\infty} (x-\mu) \cdot (x-\mu) \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

Procedendo per mezzo dell'integrazione per parti, si ha che

$$\mathbb{E}[(x-\mu)^2] = \left[(x-\mu) \cdot -\frac{\sigma}{\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \right]_{-\infty}^{\infty} + \int_{-\infty}^{\infty} \frac{\sigma}{\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} = 0 + \sigma^2 \int_{-\infty}^{\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} = \sigma^2$$

Il Lemma 1 sulle variabili casuali tradisce una utilissima proprietà delle variabili casuali normali: data una variabile casuale $X \sim \mathcal{N}(\mu, \sigma)$ e un insieme $B \in \mathcal{B}(\mathbb{R})$ di cui è necessario misurare la *probabilità*, la seguente relazione è valida

$$P(X \in B) = P(n_X(X) \in n_X(B))$$

dove $n_X(x) : \mathbb{R} \rightarrow \mathbb{R}$ è la funzione di normalizzazione, ovvero $n_X(x) = \frac{x-\mu}{\sigma}$.

6.4.2 Variabili casuali uniformi

Una variabile casuale (assolutamente continua) X è detta *uniforme* su un intervallo $I \subseteq \mathbb{R}$ qualora la sua funzione di densità di probabilità fosse strutturata nel seguente modo:

$$f_X(x) = \frac{1}{\mu(I)} \mathbb{1}_I(x)$$

dove μ è la misura standard sulla linea reale.

Valore atteso (o media) e varianza di una variabile casuale uniforme $X \sim U((a, b))$ sono, rispettivamente

$$\begin{aligned} \mathbb{E}[X] &= \int_{-\infty}^{\infty} x \frac{1}{b-a} \mathbb{1}_{(a,b)}(x) dx = \frac{1}{b-a} \int_a^b x dx = \frac{1}{b-a} \left[\frac{1}{2} x^2 \right]_a^b = \frac{1}{2(b-a)} [b^2 - a^2] = \frac{b+a}{2} \\ \text{var}(X) &= \mathbb{E}[(x-\mu_X)^2] = \mathbb{E}[x^2] - \mu_X^2 = \int_{-\infty}^{\infty} x^2 \frac{1}{b-a} \mathbb{1}_{(a,b)}(x) dx - \mu_X^2 = \int_a^b x^2 \frac{1}{b-a} dx - \mu_X^2 = \\ &= \frac{1}{b-a} \left[\frac{1}{3} x^3 \right]_a^b - \mu_X^2 = \frac{b^3 - a^3}{3(b-a)} - \left(\frac{b+a}{2} \right)^2 = \frac{4(a^2 + b^2 + ab) - 3(a^2 + b^2 + 2ab)}{12} = \frac{(b-a)^2}{12} \end{aligned}$$

6.4.3 Variabili casuali esponenziali

Una variabile casuale (assolutamente continua) X è detta *esponenziale* qualora la sua funzione di densità di probabilità fosse strutturata nel seguente modo

$$f_X(x) = \lambda e^{-\lambda x} \cdot \mathbb{1}_{(0,+\infty)}(x)$$

Valore atteso e varianza di una variabile casuale esponenziale $X \sim \text{Exp}(\lambda)$ sono, rispettivamente

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x \lambda e^{-\lambda x} \mathbb{1}_{(0,+\infty)}(x) dx = \int_0^{\infty} x \lambda e^{-\lambda x} dx = \lambda \left[-\frac{x}{\lambda} e^{-\lambda x} \Big|_0^{\infty} + \int_0^{\infty} \frac{1}{\lambda} e^{-\lambda x} dx \right] = \lambda \cdot \frac{1}{\lambda^2} = \frac{1}{\lambda}$$

$$\text{var}(X) = \mathbb{E}[x^2] - \mu_X^2 = \int_0^\infty x^2 \lambda e^{-\lambda x} dx - \mu_X^2 = \left[-x^2 e^{-\lambda x} \Big|_0^\infty + 2 \int_0^\infty x e^{-\lambda x} dx \right] - \mu_X^2 = \frac{2\mu_X}{\lambda} - \mu_X^2 = \frac{1}{\lambda^2}$$

Le funzioni di distribuzione cumulativa di probabilità e distribuzione cumulativa di sopravvivenza sono, rispettivamente

$$F_X(x) = \int_{-\infty}^x f_X(x) dx = \begin{cases} \int_0^x \lambda e^{-\lambda t} dt, & x \geq 0 \\ 0, & x < 0 \end{cases} = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

$$S_X(x) = 1 - F_X(x) = \begin{cases} e^{-\lambda x}, & x \geq 0 \\ 1, & x < 0 \end{cases}$$

6.5 Algebra su variabili casuali

Siano $X, Y : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ due variabili casuali discrete e sia $T = X + Y$ una nuova variabile casuale. Allora

$$\forall k \in T(\Omega), P_T(T = k) = P_T(X + Y = k)$$

Si selezionano allora la partizione dell'evento certo

$$A_j = \{Y^{-1}(j) : j \in Y(\Omega)\}, \quad \bigcup_{j \in Y(\Omega)} A_j = \Omega$$

Allora, per la formula delle probabilità totali, si ha che

$$P_T(X + Y = k) = \sum_{j \in Y(\Omega)} P((X + Y = k)_T \cap (Y = j)_Y) = \sum_{j \in Y(\Omega)} P((X = k - j)_X \cap (Y = j)_Y)$$

Qualora X e Y fossero indipendenti, la formula si semplifica a

$$\sum_{j \in Y(\Omega)} P_X(X = k - j) P_Y(Y = j) \implies P_T = P_X * P_Y \quad (P_T \text{ è la convoluzione discreta di } P_X, P_Y)$$

Fossero X, Y state continue, allora

$$f_T(t) = \int_{-\infty}^{\infty} f_X(t - \tau) f_Y(\tau) d\tau \implies f_T = f_X * f_Y \quad (P_T \text{ è la convoluzione continua di } P_X, P_Y)$$

Alcuni casi notevoli sono:

1. $X \sim P(\lambda) \perp Y \sim P(\mu) \implies X + Y \sim P(\lambda + \mu)$
2. $X \sim B(n, p) \perp Y \sim B(m, p) \implies X + Y \sim B(n + m, p)$
3. $X \sim \mathcal{N}(\mu_x, \sigma_x^2) \perp Y \sim \mathcal{N}(\mu_y, \sigma_y^2) \implies aX + bY + c \sim \mathcal{N}(a\mu_x + b\mu_y + c, a^2\sigma_x^2 + b^2\sigma_y^2)$

Un'altra operazione fra variabili casuali comune è, date due variabili casuali $X, Y : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$, prenderne il *massimo* o *minimo*, ovvero

$$T = \max(X, Y), \text{ oppure } T = \min(X, Y)$$

Assumendo $T = \max(X, Y)$, si osservi come

$$F_T(x) = P_T(T \leq x) = P_T(\max(X, Y) \leq x) = P((X \leq x)_X \cap (Y \leq x)_Y)$$

se $X \perp Y$

$$P((X \leq x)_X \cap (Y \leq x)_Y) = P_X(X \leq x) P_Y(Y \leq x) = F_X(x) F_Y(x)$$

Invece, assumendo $T = \min(X, Y)$, si può osservare come

$$S_T(x) = P_T(T \geq x) = P_T(\min(X, Y) \geq x) = P((X \geq x)_X \cap (Y \geq x)_Y)$$

se $X \perp Y$

$$P((X \geq x)_X \cap (Y \geq x)_Y) = P_X(X \geq x) P_Y(Y \geq x) = S_X(x) S_Y(x)$$

7 Vettori di variabili casuali

Siano $X_1, X_2, \dots, X_n : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ variabili casuali su un'unico spazio di probabilità determinato dalla terna $(\Omega, \mathcal{F}, P)$. Si intende allora per *vettore aleatorio* oppure *variabile casuale vettoriale* la seguente espressione

$$\mathbf{X} = (X_1, X_2, \dots, X_n) : \Omega \rightarrow \mathbb{R}^n$$

La misura di probabilità indotta in $\mathbb{R}^n$ da $\mathbf{X}$ è data da

$$P_{\mathbf{X}}(\mathbf{X} \in \Lambda \subseteq \mathbb{R}^n) = P(\mathbf{X}^{-1}(\Lambda))$$

7.1 Vettori aleatori discreti

Un vettore aleatorio $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ è detto *discreto* qualora lo siano anche tutti i suoi componenti. Nel caso discreto, la misura di probabilità indotta in $\mathbb{R}^n$ da $\mathbf{X}$ è data da

$$P_{\mathbf{X}}(\mathbf{X} \in \Lambda) = \sum_{\lambda \in \Lambda \cap \mathbf{X}(\Omega)} P(\lambda)$$

$$P_{\mathbf{X}}(\mathbf{X} = \mathbf{a} \in \mathbb{R}^n) = P(X_1 = a_1, X_2 = a_2, \dots, X_n = a_n) = P\left(\bigcap_{i=1}^n X_i^{-1}(a_i)\right)$$

7.2 Vettori aleatori continui

Un vettore aleatorio $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ è detto *continuo* (o *assolutamente continuo*) qualora lo siano anche tutti i suoi componenti. Nel caso continuo, la misura di probabilità indotta in $\mathbb{R}^n$ da $\mathbf{X}$ è data da

$$f_{\mathbf{X}} : \mathbb{R}^n \rightarrow \mathbb{R}$$

$$P_{\mathbf{X}}(\mathbf{X} \in \Lambda \subseteq \mathbb{R}^n) = \int_{\Lambda} f_{\mathbf{X}} d\mathbf{x}$$

dove $f_{\mathbf{X}}$ è detta funzione di densità di probabilità di $\mathbf{X}$. Questa funzione deve rispettare le seguenti condizioni

- Non-negatività

$$f_{\mathbf{X}}(\mathbf{x}) \geq 0, \forall \mathbf{x} \in \mathbb{R}^n$$

- Misura di $\mathbb{R}^n$

$$\int_{\mathbb{R}^n} f_{\mathbf{X}} d\mathbf{x} = 1$$

Inoltre, è possibile determinare le densità di probabilità *marginali* $f_{X_1}, f_{X_2}, \dots, f_{X_n}$ a partire dalla densità di probabilità congiunta ($f_{\mathbf{X}}$), infatti

$$f_{X_k}(x) = \int_{\mathbb{R}^{n-1}} f_{\mathbf{X}}(\dots, x_k = x, \dots) d\mathbf{x}$$

7.3 Valore atteso di vettori aleatori

Sia $\mathbf{X} = (X_1, \dots, X_n) : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ un vettore aleatorio. Si dice valore atteso di $\mathbf{X}$ la seguente espressione

$$\mathbb{E}[\mathbf{X}] = \sum_{\mathbf{x} \in \mathbf{X}(\Omega)} \mathbf{x} P_{\mathbf{X}}(\mathbf{X} = \mathbf{x})$$

nel caso in cui $\mathbf{X}$ sia un vettore aleatorio discreto, oppure

$$\mathbb{E}[\mathbf{X}] = \int_{\mathbb{R}^n} \mathbf{x} f_{\mathbf{X}} d\mathbf{x}$$

nel caso in cui $\mathbf{X}$ sia un vettore aleatorio continuo

Sia $\mathbf{X} = (X_1, \dots, X_n) : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ un vettore aleatorio e sia $g : \mathbb{R}^n \rightarrow \mathbb{R}^n$ una funzione regolare (che mantiene la misurabilità) Allora

$$g \circ \mathbf{X} : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$$

è a sua volta un vettore aleatorio il cui valore atteso diventa

$$\mathbb{E}[g(\mathbf{X})] = \int_{\mathbb{R}^n} g(\mathbf{x}) f_{\mathbf{X}} d\mathbf{x}$$